

Modelagem da Relação de Vendas de Cadeirinhas Infantis

a, a, a

^aDepartamento de Ciência da Computação - UFCG

Resumo

Este trabalho aplica a Regressão Linear Múltipla (RLM) para modelar o volume de vendas de cadeirinhas infantis (Sales) a partir da base de dados Carseats. O objetivo principal é quantificar o impacto de fatores como precificação, investimento em publicidade, perfil demográfico e exposição do produto no desempenho de vendas em 400 lojas, com foco na inferência estatística. A metodologia abrange uma análise exploratória preliminar, seguida pelo ajuste do modelo e pela avaliação da significância das variáveis explicativas por meio de testes de hipótese individuais e em conjunto. Além disso, o estudo constrói intervalos de confiança para os coeficientes, seleciona um modelo final ajustado e calcula intervalos de confiança e de predição para cenários hipotéticos. Dessa forma, o relatório vai além da predição, oferecendo uma interpretação prática e fundamentada das dinâmicas comerciais no varejo.

Áreas do Conhecimento:

estatística aplicada, modelagem preditiva, inferência estatística

Palavras-Chave:

regressão linear múltipla, testes de hipótese, intervalos de confiança, seleção de modelos, análise de vendas

1 Introdução

A previsão do volume de vendas de um produto a partir de fatores como preço, concorrência, publicidade e características demográficas da região de venda constitui um problema recorrente em análises de varejo. A base Carseats, com dados simulados de vendas de cadeirinhas infantis em 400 lojas, permite ilustrar como esses fatores — precificação própria e da concorrência, investimento em publicidade, perfil socioeconômico da região (renda, população, idade, escolaridade) e a qualidade da exposição do produto na prateleira — se relacionam com o desempenho de vendas, e como essa relação pode ser quantificada e testada estatisticamente.

Neste trabalho, o objetivo é modelar as vendas (Sales, em milhares de unidades) a partir das demais variáveis disponíveis na base, utilizando regressão linear múltipla (RLM) como ferramenta central de análise. Mais do que ajustar um modelo preditivo, o interesse do trabalho está em aplicar, sobre os coeficientes estimados, os instrumentos de inferência estatística estudados na disciplina: testes de hipótese sobre a significância de cada variável explicativa e intervalos de confiança para os parâmetros do modelo e para o valor médio esperado da resposta.

Especificamente, buscamos: (i) descrever a base de dados e realizar uma análise exploratória uni e bivariada; (ii) ajustar um modelo de regressão linear múltipla com as variáveis explicativas disponíveis; (iii) testar formalmente a significância de cada coeficiente por meio de testes de hipótese individuais (teste t) e da significância conjunta do modelo (teste F); (iv) construir intervalos de confiança para os coeficientes estimados, interpretando seu significado prático; (v) selecionar um modelo final com base nesses resultados; e (vi) apresentar, para valores hipotéticos das variáveis explicativas, os intervalos de confiança para o valor médio esperado das vendas e os intervalos de predição para uma nova observação, discutindo a diferença entre ambos.

1.1 Modelo de regressão linear múltipla

A ideia da regressão linear múltipla é explicar uma variável resposta Y (no nosso caso, Sales, o volume de vendas em milhares de unidades) a partir de várias variáveis explicativas ao mesmo tempo, supondo que a relação entre elas é (aproximadamente) uma soma ponderada:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_{p-1} X_{i,p-1} + \varepsilon_i$$

em que β_0 é o intercepto, cada β_j mede o efeito da variável X_j sobre as vendas (mantendo as outras variáveis fixas) e ε_i é o erro, ou seja, a parte das vendas que o modelo não consegue explicar. Usando todas as variáveis da base Carseats, o modelo fica:

$$\begin{aligned}\text{Sales}_i = & \beta_0 + \beta_1 \text{CompPrice}_i + \beta_2 \text{Income}_i + \beta_3 \text{Advertising}_i + \beta_4 \text{Population}_i \\ & + \beta_5 \text{Price}_i + \beta_6 \text{ShelveLocGood}_i + \beta_7 \text{ShelveLocMedium}_i + \beta_8 \text{Age}_i \\ & + \beta_9 \text{Education}_i + \beta_{10} \text{UrbanYes}_i + \beta_{11} \text{USYes}_i + \varepsilon_i\end{aligned}$$

ShelveLocGood e ShelveLocMedium indicam se a exposição do produto é boa ou média (a categoria “Bad” fica implícita no intercepto), e UrbanYes/USYes indicam se a loja é urbana e se é dos EUA (a categoria “Não” fica implícita).

Os β_j são estimados pelo método dos mínimos quadrados, que escolhe a reta (ou “plano”) que minimiza a soma dos quadrados dos erros de previsão. Para que os testes de hipótese e os intervalos de confiança que vamos usar façam sentido, o modelo assume que:

- a relação entre as variáveis e as vendas é de fato aproximadamente linear;
- os erros, em média, valem zero (o modelo não erra sistematicamente para cima ou para baixo);
- os erros têm variância parecida em toda a faixa de valores (não erra muito mais para lojas grandes do que para pequenas, por exemplo);
- os erros de uma loja não influenciam o erro de outra;
- os erros seguem aproximadamente uma distribuição normal;
- as variáveis explicativas não são muito redundantes entre si (isto será checado mais à frente com o VIF).

1.2 Testes de hipótese e intervalos de confiança

Depois de ajustar o modelo, queremos saber quais variáveis realmente importam para explicar as vendas. Para cada coeficiente β_j , fazemos um teste de hipótese:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0$$

Ou seja, H_0 diz que a variável não tem efeito nenhum sobre as vendas. A estatística de teste é

$$t_j = \frac{\hat{\beta}_j}{\text{ep}(\hat{\beta}_j)}$$

que compara o tamanho do coeficiente estimado com o seu erro padrão. Quanto maior (em módulo) esse t_j , mais evidência temos de que a variável realmente tem efeito. Na prática, olhamos o p-valor: se for menor que 0,05, rejeitamos H_0 e dizemos que a variável é estatisticamente significativa.

Além de testar cada variável separadamente, existe um teste para saber se o modelo como um todo é útil — o teste F :

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-1} = 0$$

isto é, nenhuma das variáveis explica as vendas. Se o p-valor do teste F for pequeno, rejeitamos essa hipótese e concluímos que pelo menos uma variável do modelo ajuda a explicar as vendas.

Também calculamos intervalos de confiança para cada β_j , que dão uma faixa de valores plausíveis para o efeito real da variável (e não só um número). O intervalo de 95% de confiança é

$$\hat{\beta}_j \pm t_{0,025, n-p} \cdot \text{ep}(\hat{\beta}_j)$$

Na prática, dizemos que temos 95% de confiança de que o verdadeiro efeito da variável está dentro desse intervalo. Uma coisa útil: se o intervalo não contém o zero, isso é equivalente a rejeitar H_0 no teste t — só que o intervalo ainda nos diz o tamanho plausível do efeito, não só se ele existe.

1.3 Diagnóstico do modelo

Antes de confiar nos testes e intervalos acima, é preciso checar se o modelo está bem ajustado. Três coisas são verificadas: multicolinearidade, comportamento dos resíduos e observações estranhas na base.

Multicolinearidade acontece quando duas ou mais variáveis explicativas carregam informação muito parecida (por exemplo, preço próprio e preço da concorrência podem andar juntos). Isso deixa as estimativas dos coeficientes instáveis, mesmo que o modelo continue prevendo bem. Medimos isso com o VIF (fator de inflação de variância) de cada variável:

$$VIF_j = \frac{1}{1 - R_j^2}$$

em que R_j^2 vem de uma regressão dessa variável contra todas as outras. Na prática, usamos a regra $VIF_j > 10$ como sinal de multicolinearidade preocupante.

Análise dos resíduos: olhamos gráficos simples para checar se as suposições do modelo fazem sentido — resíduos contra valores previstos (para ver se não sobrou nenhum padrão que o modelo devia ter capturado), e um gráfico quantil-quantil (para checar se os resíduos se parecem com uma normal). O gráfico de envelope simulado é um reforço desse último ponto: compara os resíduos observados com uma faixa “esperada” caso o modelo estivesse correto; se a maioria dos pontos fica dentro da faixa, é um bom sinal.

Por fim, olhamos observações que podem estar distorcendo o modelo, usando três critérios simples:

- **Ponto atípico (outlier):** o modelo erra muito para essa observação. Critério: resíduo padronizado $|t_i| > 2$.
- **Ponto de alavanca:** a observação tem valores de variáveis explicativas muito fora do padrão das demais. Critério: $h_{ii} > 2p/n$.
- **Ponto influente:** se essa observação for removida, os coeficientes mudam bastante. Critério: distância de Cook $D_i > 4/n$.

Uma observação pode ser só uma coisa (por exemplo, atípica sem ser influente) ou várias ao mesmo tempo. O importante é checar se, tirando essas observações e reajustando o modelo, as conclusões continuam as mesmas

1.4 Inferência preditiva

Depois de escolher o modelo final, dá para usá-lo para prever vendas em situações hipotéticas — por exemplo, “quanto uma loja com determinado preço, publicidade e exposição venderia?”. Só que existem duas perguntas diferentes que podemos fazer, e cada uma tem seu próprio intervalo:

Intervalo de confiança para a média: qual é a venda média esperada entre todas as lojas com essas mesmas características? A incerteza aqui vem só de estarmos estimando os coeficientes do modelo com uma amostra (e não a população toda):

$$\hat{Y}_h \pm t_{0,025, n-p} \cdot \text{ep}(\hat{Y}_h)$$

Intervalo de predição: qual seria a venda de uma loja específica, nova, com essas características? Aqui, além da incerteza sobre a média, somamos a variabilidade natural entre lojas (nem toda loja com o mesmo perfil vende exatamente a mesma coisa):

$$\hat{Y}_h \pm t_{0,025, n-p} \cdot \sqrt{\text{ep}(\hat{Y}_h)^2 + \hat{\sigma}^2}$$

Por causa dessa variabilidade extra, o intervalo de predição é sempre mais largo que o de confiança, para o mesmo cenário. A estimativa pontual (o valor previsto) é igual nos dois casos — a diferença está só na largura do intervalo, dependendo se queremos prever uma média ou uma loja individual.

2 Resultados

2.1 Descrição da base de dados

Tabela 1: Variáveis da base de dados Carseats, descrição e unidade de medida.

Variável	Descrição	Unidade
Sales	Vendas de cadeirinhas infantis (variável resposta)	milhares de unidades
CompPrice	Preço cobrado pelo concorrente mais próximo	dólares
Income	Renda média da comunidade da região de venda	milhares de dólares
Advertising	Orçamento de publicidade local da loja	milhares de dólares
Population	Tamanho da população da região de venda	milhares de habitantes
Price	Preço cobrado pela empresa pela cadeirinha infantil	dólares
ShelveLoc	Qualidade da localização do produto na prateleira	categórica (Bad, Medium, Good)

Variável	Descrição	Unidade
Age	Idade média da população local	anos
Education	Nível educacional da região de venda	anos de estudo
Urban	Loja localizada em área urbana	categórica (Yes, No)
US	Loja localizada nos Estados Unidos	categórica (Yes, No)

A base Carseats possui $n = 400$ observações (lojas) e 11 variáveis (Tabela 1), sendo Sales a variável resposta, sete variáveis quantitativas (CompPrice, Income, Advertising, Population, Price, Age, Education) e três variáveis categóricas (ShelveLoc, Urban, US). Não há valores ausentes em nenhuma das variáveis.

2.2 Análise exploratória

2.2.1 Estatísticas descritivas

Tabela 2: Estatísticas descritivas das variáveis quantitativas.

Variável	Média	Mediana	Desvio.padrão	Q1	Q3
Sales	7.50	7.49	2.82	5.39	9.32
CompPrice	124.97	125.00	15.33	115.00	135.00
Income	68.66	69.00	27.99	42.75	91.00
Advertising	6.64	5.00	6.65	0.00	12.00
Population	264.84	272.00	147.38	139.00	398.50
Price	115.80	117.00	23.68	100.00	131.00
Age	53.32	54.50	16.20	39.75	66.00
Education	13.90	14.00	2.62	12.00	16.00

Tabela 3: Vendas (Sales), por qualidade de exposição na prateleira (ShelveLoc).

Qualidade da prateleira	Média	Mediana	Desvio-padrão
Bad	5.52	5.21	2.36
Good	10.21	10.50	2.50
Medium	7.31	7.38	2.27

A Tabela 2 mostra que as vendas (Sales) têm média de 7,50 mil unidades e mediana de 7,49 mil unidades, valores muito próximos, o que sugere uma distribuição sem grande assimetria; o desvio-padrão de 2,82 indica dispersão moderada em torno da média. Entre as variáveis explicativas, chama atenção a grande amplitude de Population (de 10 a 509 mil habitantes) e de Price (de 24 a 191 dólares), refletindo lojas em contextos bastante diferentes. Advertising tem mediana igual a 5 e mínimo igual a 0, indicando que uma parcela relevante das lojas não investe em publicidade local.

A Tabela 3 evidencia uma relação clara entre a qualidade da exposição do produto e o volume de vendas: lojas com prateleira classificada como “Good” vendem, em média, quase o dobro das lojas com prateleira “Bad” (10,21 contra 5,52 mil unidades), com a categoria “Medium” (7,31 mil unidades) numa posição intermediária. Essa diferença expressiva já sinaliza que ShelveLoc deve ser uma variável explicativa importante no modelo de regressão.

2.2.2 Visualização por categoria

(texto interpretando o gráfico)

2.2.3 Matriz de correlação e dispersão

(texto interpretando as correlações — pode ser escrito em conjunto, pois a leitura costuma ficar mais fácil para quem produziu as estatísticas descritivas)

2.3 Modelo inicial: todas as variáveis explicativas

(texto: R^2 e significância dos coeficientes)

2.4 Testes de hipótese e multicolinearidade (VIF)

(texto: resultado dos testes t individuais, teste F conjunto e discussão sobre o VIF — há ou não multicolinearidade relevante?)

2.5 Seleção do modelo final

(texto justificando o modelo final escolhido)

2.6 Diagnóstico do modelo selecionado

2.6.1 Pontos atípicos, de alavanca e influentes

2.6.2 Impacto da remoção dos pontos influentes

2.7 Regressão com variáveis dummy

```
# Colega 2:  
# incluir ShelveLoc, Urban e US no modelo  
# discutir a categoria de referência
```

2.8 Comparação geral dos modelos

3 Previsões

3.1 Intervalo de confiança para o valor médio esperado

(texto de interpretação prática)

3.2 Intervalo de predição para uma nova observação

(texto de interpretação prática)

4 Conclusão

(síntese: principais fatores associados às vendas, qualidade do modelo, limitações e distinção prática entre intervalo de confiança e intervalo de predição)